EnKo Translation

자연어 처리를 이용한 번역기

지도교수: 양희경 교수님
팀장: 서현수
팀원: 김부용, 김현중, 최다경

목차 및 발표순서

- 주제 - 자연어 처리를 이용한 번역기
- 필요성
- 기술조사 - RNN,Attention,Transformer 기술과 오픈소스
- 특정회사의 관심기술 - 네이버의 파파고 API
- 기술시연
- 사업화전략
- 향후 발전계획
- 역할 및 일정

주제

자연어를 컴퓨터가
이해할 수 있도록
처리하는 일

자연어 처리를 이용한 번역서비스

인간이 일상 속에서
자연스럽게 사용하는 언어
자연어 데이터 = 말뭉치 or 코퍼스 (Corpus)

NMT
- 딥러닝 기반 영역
- 전체 문장을 하나의 번역단위로 간주
  모든 정보, 네트워크 통째로 학습
- 한번도 학습되지 않은 문장도
  번역가능

필요성

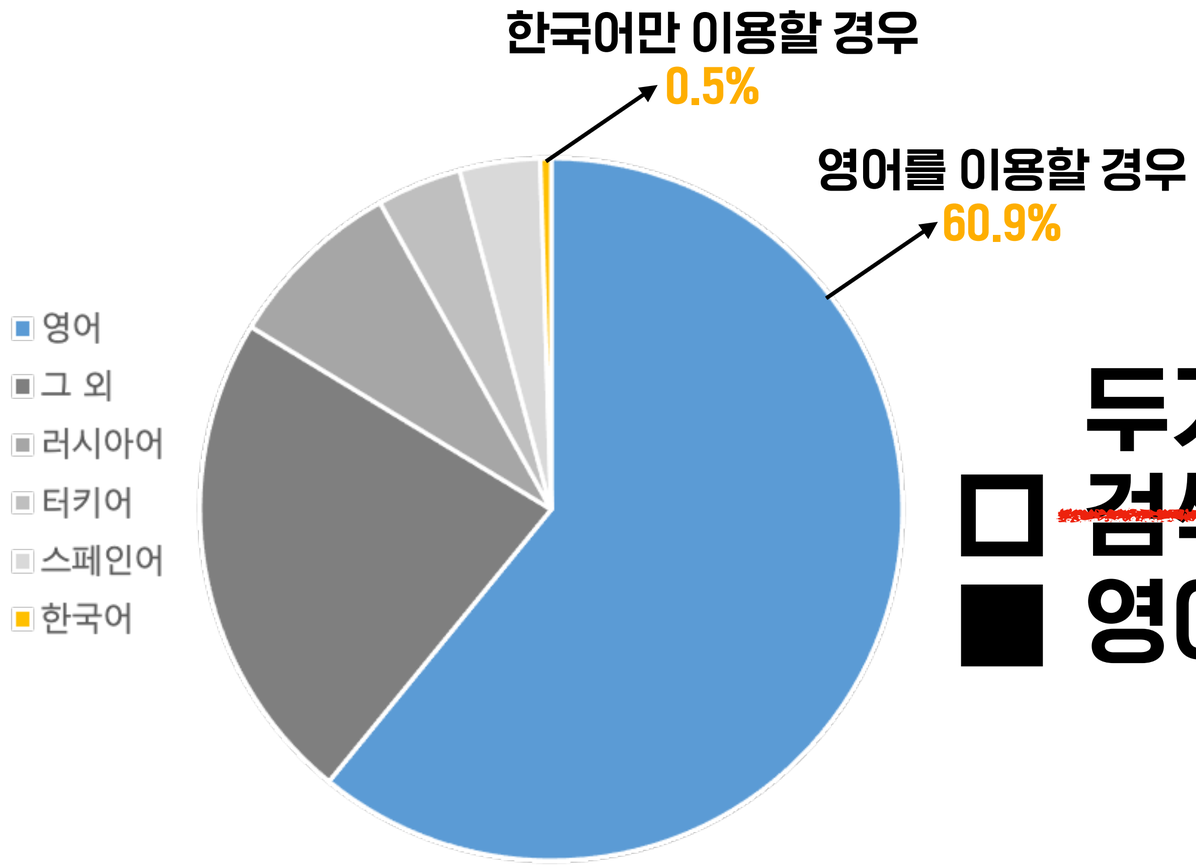

언어별 웹사이트 정보량
출처: W3Techs.com, 2021 년 4 월 8 일 기준

두가지 선택지

- □ ~~검색을 위해 영어를 공부~~
- ■ 영어 공부는 컴퓨터에게 맡기기

기술조사

- RNN, ATTENTION, TRANSFORMER

RNN 기반

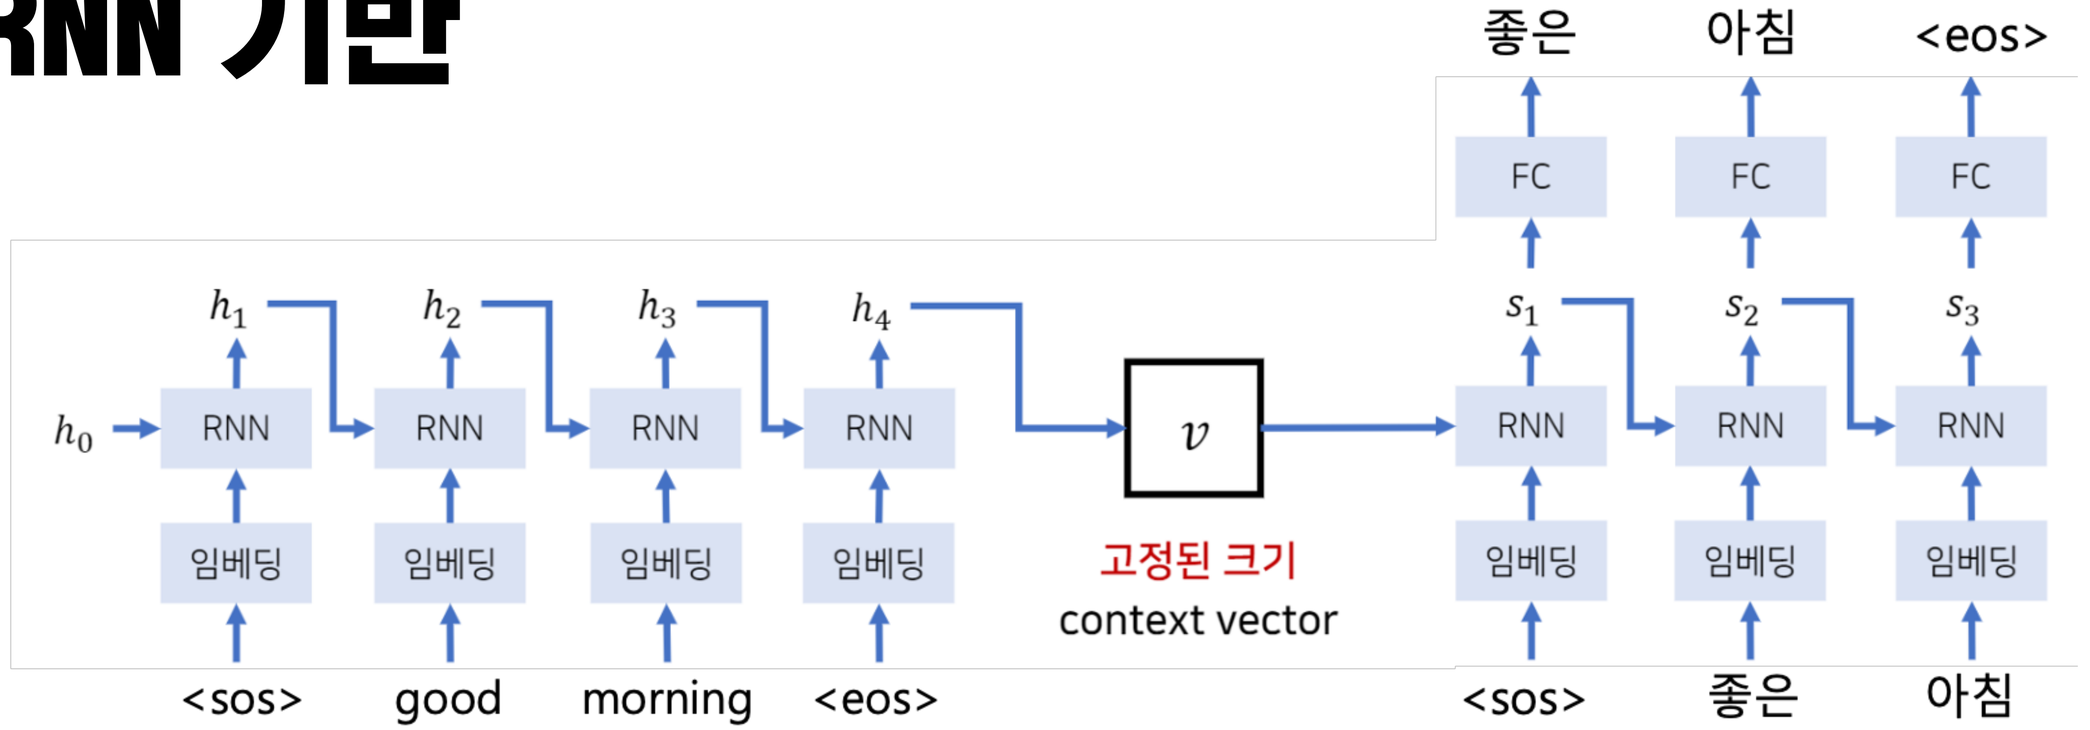

Encoder: 입력 문장을 RNN을 이용하여 context vector로 변환시켜 정보를 압축
Decoder: context vector로부터 번역 결과를 추론

한계점: context vector가 고정된 크기를 가지기 때문에
많은 정보 -> 정보손실, 성능 저하

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. arXiv preprint arXiv:1706.03762.

ATTENTION 기반

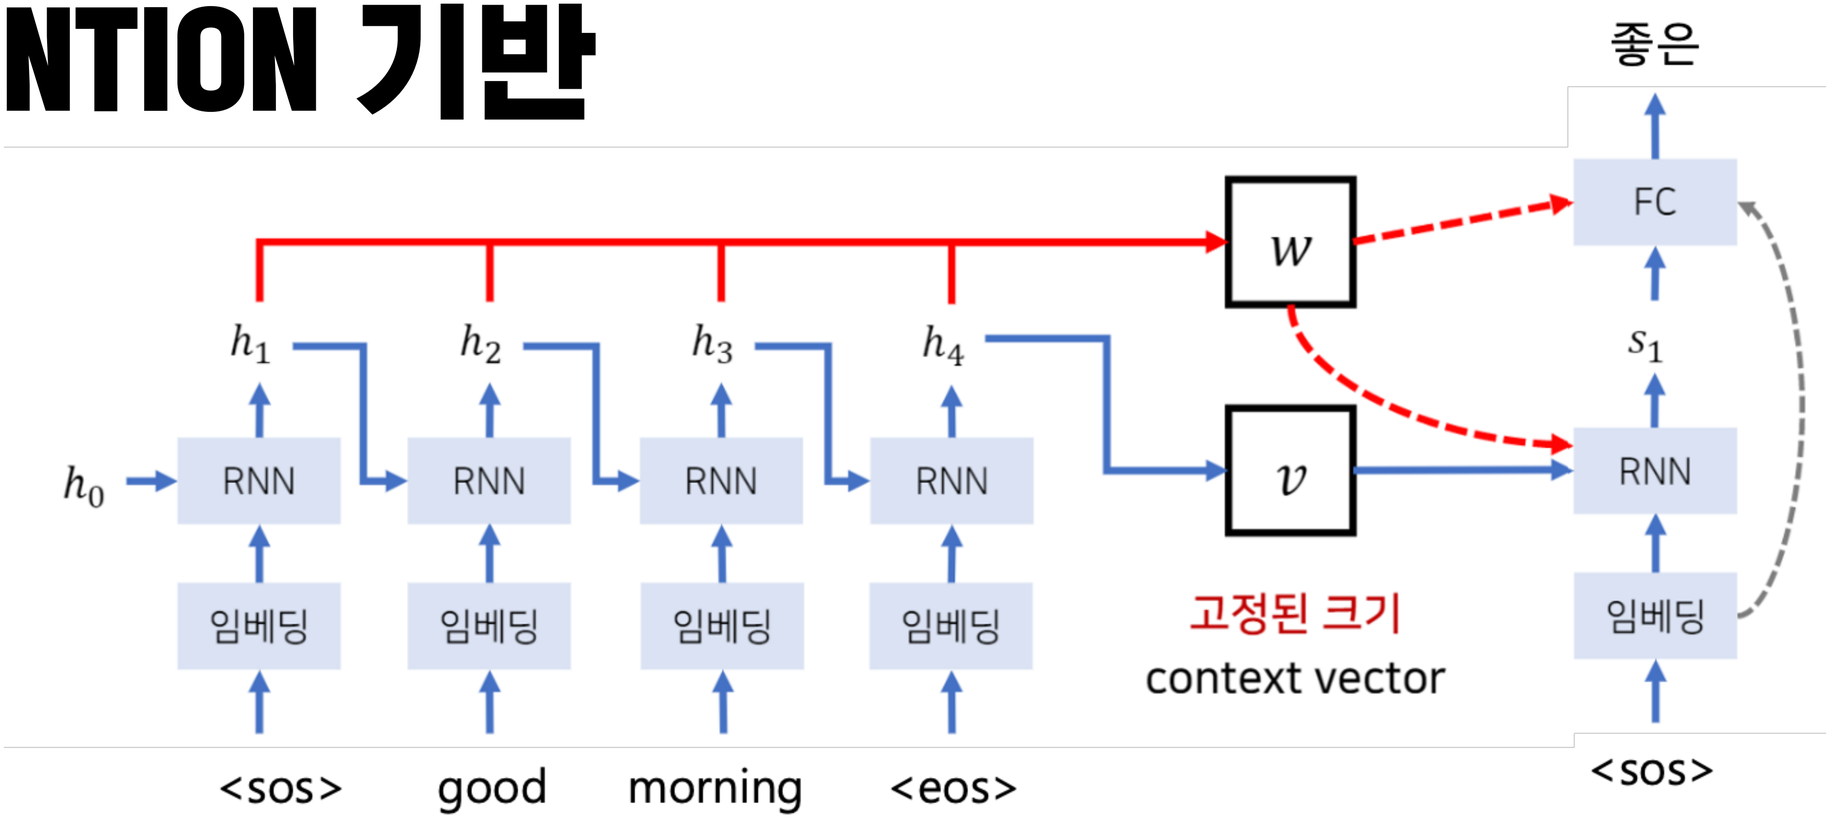

Decoder에서 출력 단어를 예측하는 매 시점(time stamp)마다
Encoder의 입력 문장의 hidden states를 참고

단, 전체 입력 문장을 전부 동일한 비율로 참고하는 것이 아닌
해당 시점에서 예측해야 할 단어와 연관이 있는
입력 단어 부분에 가중치를 높여 참고

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. arXiv preprint arXiv:1409.3215.

TRANSFORMER 기반

기존의 seq2seq의 구조인 Encoder - Decoder구조를 따르지만
RNN, CNN을 사용하지 않고 Attention만으로 구현한 모델

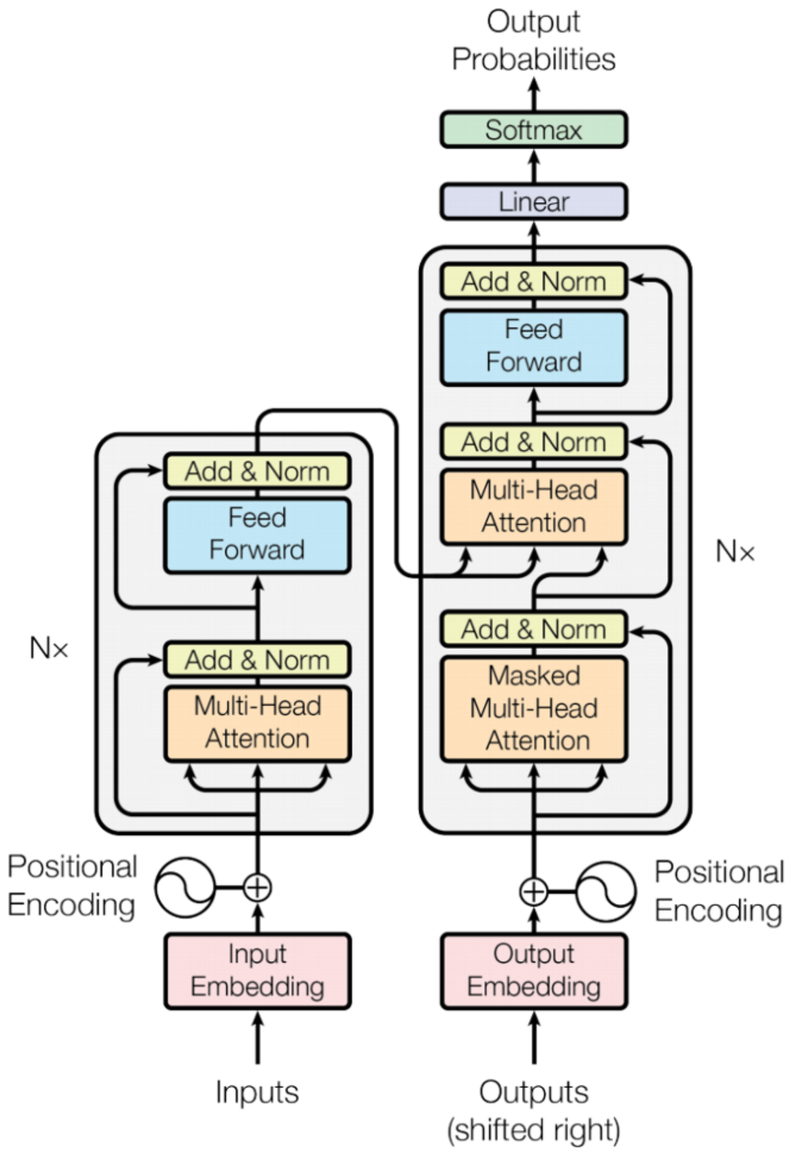

Bahdanau, D., Cho, K., & Bengio, Y. (2014). Neural machine translation by jointly learning to align and translate. arXiv preprint arXiv:1409.0473.

오픈소스

- Self Attention, Multi Head Attention
  Encoder, Decoder, Positional Encoding
  Transformer

Self Attention

```python
class SelfAttention(nn.Module):
  def __init__(self):
    super(SelfAttention,self).__init__()
    self.matmul = torch.matmul
    self.softmax = torch.softmax

  def forward(self, query, key, value, mask=None):
    key_transpose = torch.transpose(key,-2,-1)        # (bath, head num, d_k, token )
    matmul_result = self.matmul(query,key_transpose)
    d_k = key.size()[-1]
    attention_score = matmul_result/math.sqrt(d_k)

    if mask is not None:
      attention_score = attention_score.masked_fill(mask == 0, -1e20)

    softmax_attention_score = self.softmax(attention_score,dim=-1)
    result = self.matmul(softmax_attention_score,value)

    return result, softmax_attention_score
```

Query 벡터와 Key 벡터의 행렬곱

Scale: key의 제곱근으로 나눠줌

확률값과 value 벡터를 가중합

$$\text{softmax}\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) V = Z$$

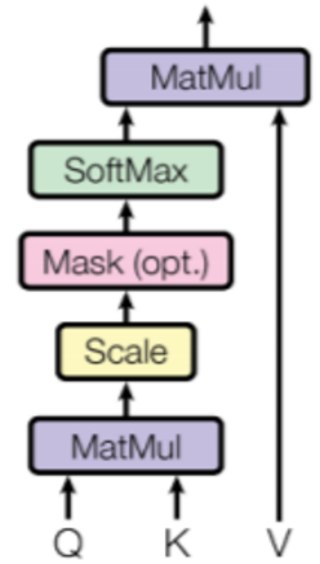

Q: Query, 현재 시점의 token을 의미
K: Key, Attention을 구하고자 하는 대상 token을 의미
V: Value, Attention을 구하고자 하는 대상 token을 의미

Multi Head Attention

```python
class MultiHeadAttention(nn.Module):
  def __init__(self, head_num =8 , d_model = 512,dropout = 0.1):
    super(MultiHeadAttention,self).__init__()

    # print(d_model % head_num)
    # assert d_model % head_num != 0 # d_model % head_num == 0 이 아닌경우 에러메세지 발생

    self.head_num = head_num
    self.d_model = d_model
    self.d_k = self.d_v = d_model // head_num

    self.w_q = nn.Linear(d_model,d_model)
    self.w_k = nn.Linear(d_model,d_model)
    self.w_v = nn.Linear(d_model,d_model)
    self.w_o = nn.Linear(d_model,d_model)

    self.self_attention = SelfAttention()
    self.dropout = nn.Dropout(p=dropout)


  def forward(self, query, key, value, mask = None):
    if mask is not None:
      # Same mask applied to all h heads.
      mask = mask.unsqueeze(1)

    batche_num = query.size(0)

    query = self.w_q(query).view(batche_num, -1, self.head_num, self.d_k).transpose(1, 2)
    key = self.w_k(key).view(batche_num, -1, self.head_num, self.d_k).transpose(1, 2)
    value = self.w_v(value).view(batche_num, -1, self.head_num, self.d_k).transpose(1, 2)

    attention_result, attention_score = self.self_attention(query, key, value, mask)

    attention_result = attention_result.transpose(1,2).contiguous().view(batche_num, -1, self.head_num * self.d_k)


    return self.w_o(attention_result)
```

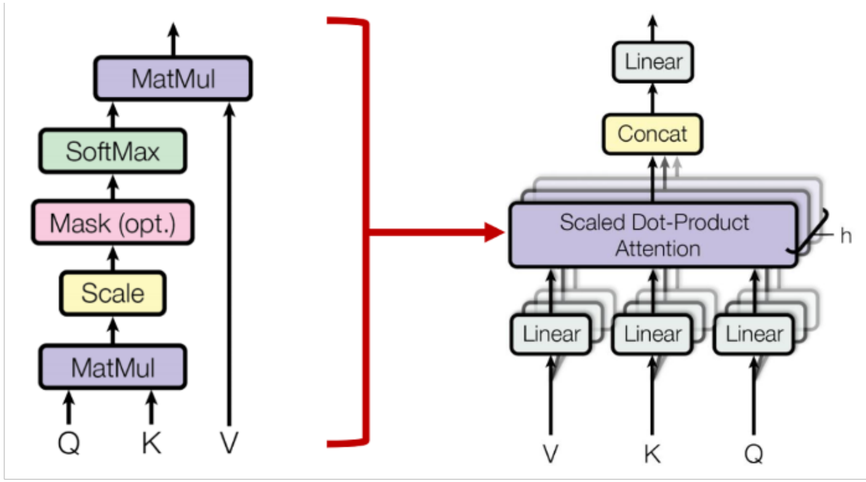

Scaled Dot-Product Attention Multi-Head Attention

Self-Attention을 8번 진행하여 각각 다르게 표현된 8개의 행렬을 하나의 행렬로 합침

Encoder, Decoder

```python
class Encoder(nn.Module):
  def __init__(self, d_model, head_num, dropout):
    super(Encoder,self).__init__()
    self.multi_head_attention = MultiHeadAttention(d_model= d_model, head_num= head_num)
    self.residual_1 = ResidualConnection(d_model,dropout=dropout)

    self.feed_forward = FeedForward(d_model)
    self.residual_2 = ResidualConnection(d_model,dropout=dropout)

  def forward(self, input, mask):
    x = self.residual_1(input, lambda x: self.multi_head_attention(x, x, x, mask))
    x = self.residual_2(x, lambda x: self.feed_forward(x))
    return x
```

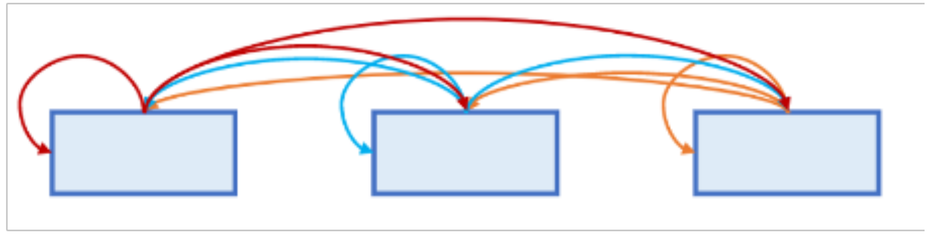

Encoder Self Attention

```python
class Decoder(nn.Module):
  def __init__(self, d_model,head_num, dropout):
    super(Decoder,self).__init__()
    self.masked_multi_head_attention = MultiHeadAttention(d_model= d_model, head_num= head_num)
    self.residual_1 = ResidualConnection(d_model,dropout=dropout)

    self.encoder_decoder_attention = MultiHeadAttention(d_model= d_model, head_num= head_num)
    self.residual_2 = ResidualConnection(d_model,dropout=dropout)

    self.feed_forward= FeedForward(d_model)
    self.residual_3 = ResidualConnection(d_model,dropout=dropout)


  def forward(self, target, encoder_output, target_mask, encoder_mask):
    # target, x, target_mask, input_mask
    x = self.residual_1(target, lambda x: self.masked_multi_head_attention(x, x, x, target_mask))
    x = self.residual_2(x, lambda x: self.encoder_decoder_attention(x, encoder_output, encoder_output, encoder_mask))
    x = self.residual_3(x, self.feed_forward)

    return x
```

Masked Multi-Head Attention

Encoder – Decoder Attention

Positional Encoding

```python
class Embeddings(nn.Module):
  def __init__(self, vocab_num, d_model):
    super(Embeddings,self).__init__()
    self.emb = nn.Embedding(vocab_num,d_model)
    self.d_model = d_model
  def forward(self, x):

    return self.emb(x) * math.sqrt(self.d_model)

class PositionalEncoding(nn.Module):
  def __init__(self, max_seq_len, d_model,dropout=0.1):
    super(PositionalEncoding,self).__init__()
    self.dropout = nn.Dropout(p=dropout)

    pe = torch.zeros(max_seq_len, d_model)

    position = torch.arange(0,max_seq_len).unsqueeze(1)
    base = torch.ones(d_model//2).fill_(10000)
    pow_term = torch.arange(0, d_model, 2) / torch.tensor(d_model,dtype=torch.float32)
    div_term = torch.pow(base,pow_term)

    pe[:, 0::2] = torch.sin(position / div_term)
    pe[:, 1::2] = torch.cos(position / div_term)

    pe = pe.unsqueeze(0)

    # pe를 학습되지 않는 변수로 등록
    self.register_buffer('positional_encoding', pe)

  def forward(self, x):
    x = x + Variable(self.positional_encoding[:, :x.size(1)], requires_grad=False)
    return self.dropout(x)
```

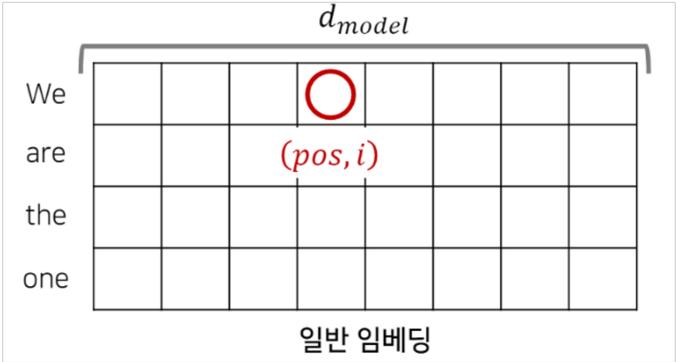

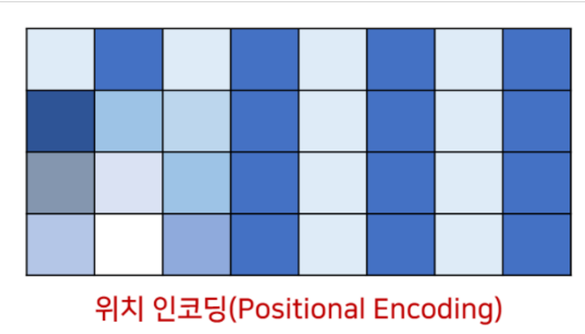

각 단어의 위치와 시퀀스 내의 다른 단어 간의 위치 차이에 대한 정보를 포함하고 있는 positional encoding을 사용해 정규화

Transformer

```python
class Transformer(nn.Module):
  def __init__(self,vocab_num, d_model, max_seq_len, head_num, dropout, N):
    super(Transformer,self).__init__()
    self.embedding = Embeddings(vocab_num, d_model)
    self.positional_encoding = PositionalEncoding(max_seq_len,d_model)

    self.encoders = clones(Encoder(d_model=d_model, head_num=head_num, dropout=dropout), N)
    self.decoders = clones(Decoder(d_model=d_model, head_num=head_num, dropout=dropout), N)

    self.generator = Generator(d_model, vocab_num)

  def forward(self, input, target, input_mask, target_mask, labels=None):
      x = self.positional_encoding(self.embedding(input))
      for encoder in self.encoders:
        x = encoder(x, input_mask)

      target = self.positional_encoding(self.embedding(target))
      for decoder in self.decoders:
        # target, encoder_output, target_mask, encoder_mask)
        target = decoder(target, x, target_mask, input_mask)

      lm_logits = self.generator(target)
      loss = None
      if labels is not None:
        # Shift so that tokens < n predict n
        shift_logits = lm_logits[..., :-1, :].contiguous()
        shift_labels = labels[..., 1:].contiguous()
        # Flatten the tokens
        loss_fct = CrossEntropyLoss(ignore_index=0)
        loss = loss_fct(shift_logits.view(-1, shift_logits.size(-1)), shift_labels.view(-1))

      return lm_logits, loss
```

```python
  def encode(self,input, input_mask):
    x = self.positional_encoding(self.embedding(input))
    for encoder in self.encoders:
      x = encoder(x, input_mask)
    return x

  def decode(self, encode_output, encoder_mask, target, target_mask):
    target = self.positional_encoding(self.embedding(target))
    for decoder in self.decoders:
      #target, encoder_output, target_mask, encoder_mask
      target = decoder(target, encode_output, target_mask, encoder_mask)

    lm_logits = self.generator(target)

    return lm_logits
```

특정 회사의 관심기술 - 네이버의 파파고 API

파파고: 국내 대표 AI 통번역 서비스

선택 이유

1. 네이버는 개발자 컨퍼런스인 'DEVIEW'를 정기적으로 개최해 현황을 발표, 접근 자료가 많음
2. 학습자를 타겟으로 개발되기 시작한 번역기
3. 네이버의 방대한 데이터셋, 오픈소스가 아닌 자체 개발 모델(Transformer 사용)
4. 국내 다른 번역 서비스와 비교해봤을 때 좋은 성능

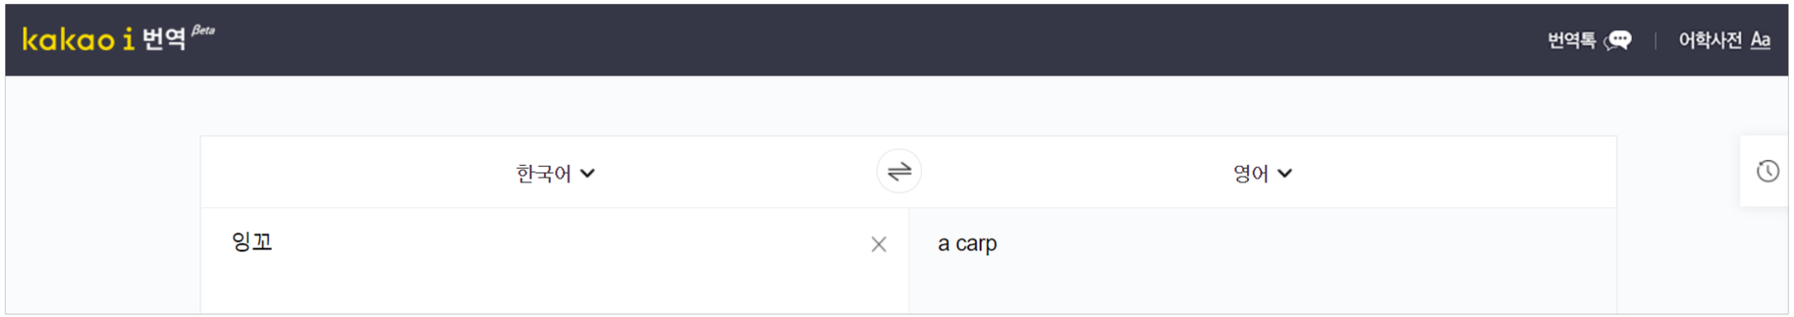

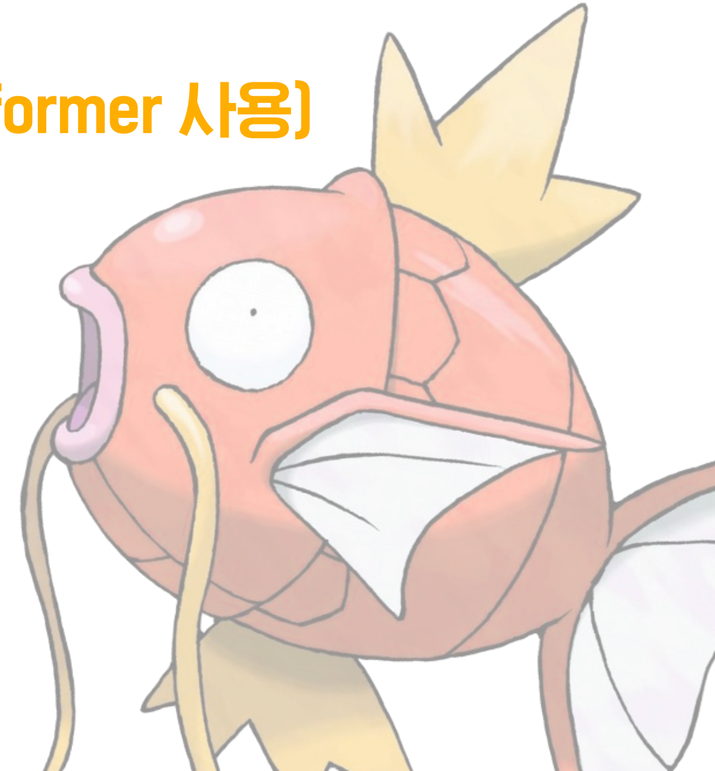

https://translate.kakao.com/
https://www.itbiznews.com/news/articleView.html?idxno=18856
https://blog.naver.com/naver_diary/222018866187
포켓몬스터

기술시연

사업화전략 - 배너광고

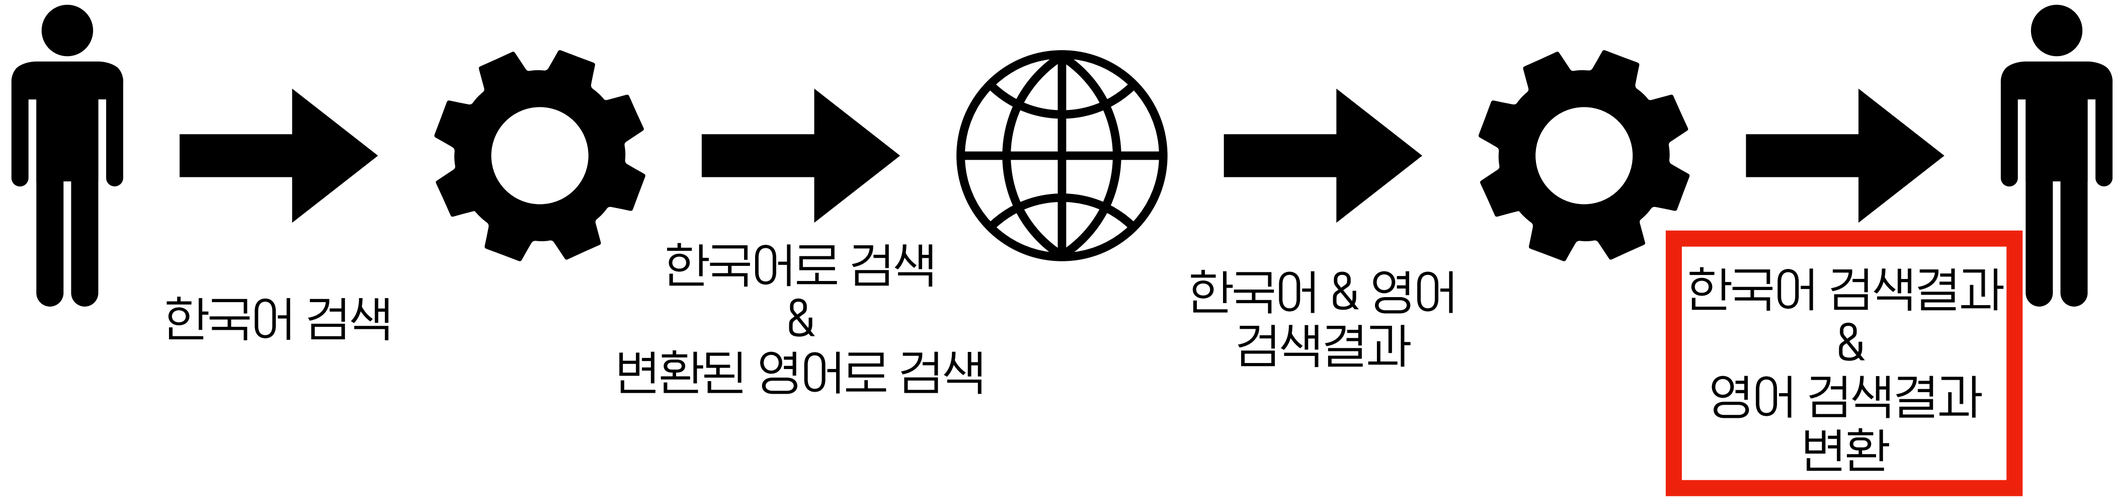

일반 웹사이트: 한국어 검색결과만 사용자에게 제공
-> 해외광고주가 해당 웹사이트를 이용한 배너광고를 할 이유가 없음

BUT !!!

한국어 & 영어 검색결과(한국어로 변환된) 사용자에게 제공
-> 해외광고주가 해당 웹사이트를 이용한 배너광고를 할 이유 충분
-> N x 본래 수익

향후 발전 계획

영어가 아닌 다른 언어로의 확장

자체모델을 커스텀한다면 사용자가 원하는 주제에 맞는
학습데이터를 사용한 맞춤형 모델로 제공해 만족도 상승

쓸모 없는 검색결과를 분류해 번역처리 되지 않도록 필터링

.....

역할 및 일정계획

역할	담당
Light Survey	공통
기술 조사 및 코드 분석	서현수, 최다경
PPT 제작, 발표	김현중
웹 사이트 구현	김부용

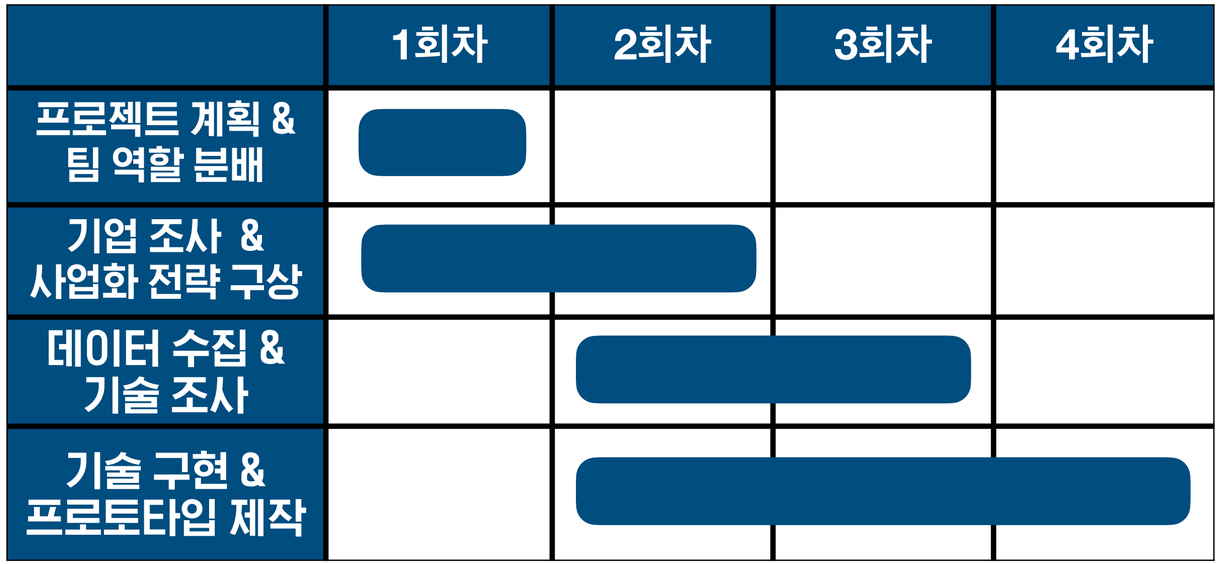

감사합니다